

個人校正：

目標100會隨肌力成長而提升最大值, 而用戶要感受“進步”變化。

角度感測器的校正。

2種資料來源。

0627 肌電圖訊號與肌肉力量之量化關係

肌電圖訊號與肌肉力量之量化關係：模型、參數與影響因素探討

摘要

肌電圖 (Electromyography, EMG) 是評估肌肉活動並間接推斷肌肉力量 (肌力) 的重要工具。學術研究已證實EMG訊號幅度與肌力間存在顯著正相關，然而此關係受多種生理、生物力學及技術因素影響，並非恆為線性。本文旨在回顧並闡述量化EMG與肌力關係的主要數學模型，包括線性回歸、非線性模型及機器學習方法。重點討論了均方根值運算 (Root Mean Square, RMS) 等關鍵EMG參數在肌力預測中的應用。同時，深入分析了影響EMG-肌力關係準確性的多種因素，如肌肉疲勞、收縮類型、電極配置等。理解這些模型與影響因素對於在臨床、運動科學及人因工程領域中準確應用EMG評估肌力至關重要。本文為研究者提供了EMG-肌力關係的理論框架，並對未來研究方向提出建議。

關鍵詞：肌電圖、肌力、均方根值、量化模型、生物力學

一、肌電圖訊號與肌肉力量之量化關係：模型、參數與影響因素探討

肌肉力量 (muscle force)，通常指肌肉或肌群在特定條件下所能產生的最大張力，是評估個體功能狀態、運動表現及康復進程的關鍵指標。肌電圖 (Electromyography, EMG) 技術通過記錄肌肉活動時產生的電生理訊號，為非侵入性地評估肌肉活化程度和間接推斷肌力提供了一種有效手段。生理學基礎表明，當肌肉需要產生更大力量時，中樞神經系統會通過增加運動單位的募集數量 (motor unit recruitment) 和提高已募集運動單位的放電頻率 (firing rate modulation) 來實現 (Enoka & Duchateau, 2008)。這些神經肌肉調控機制的增強，宏觀上表現為表面EMG (surface EMG, sEMG) 訊號幅度的增加。因此，學術界普遍認為sEMG訊號幅度與肌肉產生的力量之間存在顯著的正相關性 (Hof, 1984; Watanabe et al., 2018)。

然而，EMG訊號與肌力之間的關係並非簡單的線性一對一映射。它受到多種內在生理因素 (如肌肉結構、疲勞狀態、收縮類型) 和外在技術因素 (如電極放置、皮膚阻抗、訊號處理方法) 的複雜影響 (Carson et al., 2024; Farina et al., 2004)。

因此，準確地從**EMG**訊號預測肌力仍然是一個具有挑戰性的課題。本文旨在系統回顧用於描述**EMG**–肌力關係的主要量化模型，闡明關鍵**EMG**參數的角色，並深入探討影響該關係的主要因素，以期為相關領域的研究與實踐提供理論支持和方法學參考。

二、**EMG**–肌力關係的量化模型

為量化**EMG**訊號與肌力之間的關係，研究者們發展了多種類型的數學模型，從基礎的線性關係到複雜的機器學習算法均有應用。

方法一：線性回歸模型

最基礎且早期廣泛採用的方法是假設對**EMG**訊號進行均方根值運算（**Root Mean Square, RMS**）後得到的參數與等長收縮（**isometric contraction**）下的肌力（**F**）之間存在線性關係。其通用表達式為：

$$F = a \times \text{RMS}(\text{EMG}) + b \text{ ----- (1)}$$

其中：

- **F** 代表肌力。
- **RMS(EMG)** 代表對 **EMG** 訊號進行均方根值運算後得到的結果。
- **a** 是增益係數（斜率）。
- **b** 是截距，代表無**EMG**活動時的基礎力或模型偏移。

這兩個係數 **a** 和 **b** 通常通過實驗數據進行最小二乘法擬合得到（**Watanabe et al., 2018; Chaffin et al., 1980**）。例如，**Watanabe**等人（2018）在研究老年人股外側肌時，發現**EMG**經過**RMS**運算後的值與肌力存在顯著相關（**r = 0.36, p = 0.001**），並將此**RMS**值作為肌力預測的決定因素之一。在某些研究中，為了提升預測的準確度，可能會引入其他生理參數，如肌肉厚度（**muscle thickness, MT**），構建多元線性回歸模型：

$$F = a1 \times \text{RMS}(\text{EMG}) + a2 \times \text{MT} + b \text{ ----- (2)}$$

其中：

- **a1** 是 **EMG** 均方根值的權重係數。

- **a2** 是肌肉厚度 (**MT**) 的權重係數。

線性模型在特定條件下（如等長收縮、中低**強度**活動、非疲勞狀態）具有一定的解釋力和應用價值。

方法二：非線性模型

大量**研究**表明，尤其是在高**強度**收縮、動態收縮 (**dynamic contractions**) 或肌肉疲勞狀態下，**EMG**訊號幅度與肌力之間的關係往往呈現非線性特徵 (**Gao et al., 2017; Hof, 1984; Staudenmann et al., 2010**)。這種非線性可能源於運動單位募集策略的變化、肌纖維傳導速度的改變、肌肉內部力學特性的非線性，以及電極與訊號源之間組織的濾波效應等。雖然沒有統一的非線性模型，但常見的形式包括多項式回歸、指數模型或對數模型。一般而言，非線性關係可以概括為：

$$F \approx f(\text{RMS}(\text{EMG})) \text{----- (3)}$$

其中 **f** 代表一個非線性函數，其輸入為**EMG**訊號的均方根值。例如，**Gao**等人 (**2017**) 在**研究**肱二頭肌時，觀察到**EMG**經**RMS**運算後的值與產生的力矩之間存在明顯的非線性關係，特別是在較高力輸出水平時。建立準確的非線性模型通常需要更複雜的數據擬合技術。

方法三：機器學習與高階回歸模型

隨著計算科學的發展，機器學習 (**Machine Learning, ML**) 方法為**EMG**-肌力關係建模提供了更強大的工具。這些模型能夠處理高維度輸入特徵，並從數據中學習複雜的非線性模式，而無需預先假設特定的函數形式。常用的機器學習模型包括：

- 支持向量回歸 (**Support Vector Regression, SVR**): **SVR**通過尋找一個最優超平面來擬合數據，能夠有效處理非線性和小樣本問題。**Qijun** 和 **Fangteng (2021)** 的**研究**表明，將多種**EMG**時域特徵（如**RMS(EMG)**、積分**EMG (IEMG)**、波形長度 (**WL**)等）輸入**SVR**模型，可以實現對肌力的智能預測，並獲得較低的預測誤差。
- 人工神經網絡 (**Artificial Neural Networks, ANNs**): **ANNs**，特別是多層感知器 (**MLP**) 或更專業的網絡結構如非線性自回歸外生模型 (**Nonlinear Autoregressive with Exogenous Inputs, NARX**)，能夠學習**EMG**特徵

與肌力之間高度複雜的映射關係。**Liu**等人 (2025) 利用**NARX**神經網絡，通過**sEMG**訊號預測力矩，取得了與實際力矩間高於**0.94**的相關係數。**Xiahou**等人 (2024) 則應用基於蟻群優化的**Laguerre-Volterra**網絡模型來評估肌肉疲勞狀態下的**EMG**-肌力關係。

- **高斯混合模型 (Gaussian Mixture Models, GMM):** **Karunakaran**等人 (2020) 使用**GMM**對**EMG**特徵 (如**RMS(EMG)**、**IEMG**) 進行分群，以對應不同的徒手肌力測試 (**Manual Muscle Testing, MMT**) 等級，其**Kappa**係數達到**0.44**，證明了其在肌力分級中的潛力。
- **模糊邏輯 (Fuzzy Logic):** **Ding**等人 (2024) 結合**EMG**和慣性測量單元 (**IMU**) 的數據，利用模糊邏輯系統對脊髓損傷患者的肌力等級進行量化評估，報告了高達**0.97**的相關性。

這些先進模型通常需要大量的訓練數據，並且模型的解釋性可能不如傳統統計模型直接。

(5) 用於肌力估計的關鍵**EMG**參數

雖然**EMG**訊號包含豐富的資訊，但在肌力估計中，幅度相關參數是最常用的。

- **均方根值 (RMS):**

計算公式為：

$$\text{RMS(EMG)} = \sqrt{(1/N) * \sum (x(i)^2)}$$

其中，**x(i)** 代表第 **i** 個**EMG**數據點，**N** 是分析窗口內的數據點總數，**Σ** 代表求和運算，**^2** 代表平方運算，**sqrt** 代表平方根運算。**EMG**訊號的均方根值被廣泛認為是與肌力相關性最好的單一**EMG**幅度參數，它反映了訊號的功率 (**De Luca, 1997; Hof, 1984**)。

- **積分肌電值 (IEMG):**

計算公式為 (離散形式)：

$$\text{IEMG} = \sum |x(i)|$$

或在連續時間下表示為：

$$\text{IEMG} = \int |\text{EMG}(t)| dt$$

其中，**|x(i)|** 代表第 **i** 個**EMG**數據點的絕對值，**Σ** 代表求和運算。它代表一定時間內**EMG**訊號絕對值的累加，反映了肌肉的總活動量。

- **平均整流值 (Average Rectified Value, ARV) 或平均絕對值 (Mean Absolute Value, MAV):**

計算公式為：

$$MAV(EMG) = (1/N) * \sum |x(i)|$$

其中， $|x(i)|$ 代表第 i 個EMG數據點的**絕對值**， N 是分析窗口內的數據點總數， \sum 代表求和運算。計算比RMS簡單，也常被用作幅度指標。

- **波形長度 (Waveform Length, WL):**

計算公式為：

$$WL(EMG) = \sum |x(i) - x(i-1)|$$

其中， $x(i)$ 代表當前數據點， $x(i-1)$ 代表前一個數據點， $|...|$ 代表**絕對值**， \sum 代表求和運算。它反映了訊號的複雜度和活動**強度**，對訊號的頻率和幅度變化都很敏感。

研究表明，組合多個EMG特徵（時域、頻域或時頻域特徵）輸入到機器學習模型中，往往能比使用單一特徵獲得更準確的肌力預測結果 (Saranya & Poonguzhali, 2023; Qijun & Fangteng, 2021)。

三、影響EMG-肌力關係的因素

EMG訊號與肌力之間的關係受到多種因素的干擾和調節，理解這些因素對於準確解讀EMG數據至關重要 (Carson et al., 2024)。

- **生理因素：**
 - **肌肉疲勞 (Muscle Fatigue):** 疲勞會導致運動單位放電模式改變、肌纖維傳導速度下降，進而影響EMG的幅度和頻譜特性。在疲勞過程中，**為維持一定的力輸出，EMG幅度可能先增加（由於額外運動單位募集或放電頻率代償性增加）**，隨後在極度疲勞時可能下降，而肌力則持續下降，導致EMG-肌力關係發生變化 (Cifrek et al., 2009)。
 - **收縮類型 (Contraction Type):** 等長收縮、向心收縮 (concentric) 和離心收縮 (eccentric) 時，EMG與肌力的關係不同。通常，在**產生相同力量水平時**，離心收縮的EMG幅度低於向心和等長收縮 (Duchateau & Enoka, 2011)。

- 肌肉長度與關節角度 (**Muscle Length and Joint Angle**): 肌肉的力-長度關係決定了其在不同長度下的最大發力能力。關節角度的變化會改變肌肉的長度和力臂，進而影響**EMG**-肌力關係。
- 運動單位特性與募集策略 (**Motor Unit Properties and Recruitment Strategy**): 不同肌肉的運動單位大小、類型（快縮或慢縮）及其募集閾值不同，這會影響**EMG**訊號的產生和幅度變化。
- 個體差異 (**Individual Variability**): 年齡、性別、訓練水平、皮下脂肪厚度等均會影響**EMG**訊號的質量和**EMG**-肌力關係。例如，較厚的皮下脂肪會衰減**EMG**訊號幅度 (Farina et al., 2004)。
- 生物力學因素：
 - 力矩臂 (**Moment Arm**): 關節角度的變化不僅改變肌肉長度，也改變了肌肉產生關節力矩的力矩臂，這使得關節力矩與**EMG**的關係更加複雜。
 - 動作速度 (**Movement Velocity**): 肌肉的力-速度關係表明，向心收縮速度越快，產生的力越小；離心收縮速度越快，能承受的力越大。這會直接影響動態任務中**EMG**與力的關係。
- 技術與方法學因素：
 - 電極放置 (**Electrode Placement**): 電極的位置、方向（平行於肌纖維）、大小和電極間距對**EMG**訊號的幅度和特異性有顯著影響。不當的放置可能導致串擾 (**crosstalk**) 或記錄到非目標肌肉的活動 (Merletti et al., 2001)。SENIAM (Surface ElectroMyoGraphy for the Non-Invasive Assessment of Muscles) 等項目提供了標準化的電極放置建議。
 - 皮膚準備與阻抗 (**Skin Preparation and Impedance**): 清潔皮膚、去除角質和毛髮可以降低皮膚與電極間的阻抗，提高訊號質量。
 - 訊號處理 (**Signal Processing**): 濾波器的選擇（如帶通濾波的截止頻率）、訊號的平滑方法、時窗長度等都會影響**EMG**參數的計算結果。
 - **EMG**標準化 (**EMG Normalization**): 為了在個體間或不同測試時間點比較**EMG**數據，通常需要將**EMG**幅度對最大自主收縮 (**Maximal Voluntary Contraction, MVC**) 時的**EMG**值進行標準化。然而，準確且可重複地獲取**MVC**本身就是一個挑戰 (Burden, 2010)。

四、討論

從**EMG**訊號推斷肌力是一個複雜但極具價值的**研究**領域。線性模型為理解**EMG**－肌力基本關係提供了簡便的途徑，但在許多實際應用場景中，其準確性有限。非線性模型和先進的機器學習算法展示出更強的擬合能力和預測潛力，尤其是在處理多變量輸入和複雜動態時。然而，這些複雜模型的泛化能力和解釋性仍需進一步**研究**。

關鍵**EMG**參數中，**EMG**訊號的均方根值因其與肌力較好的一致性而被廣泛應用。但單一參數往往不足以完全捕捉肌肉活動的複雜性，多特徵融合策略是提升預測性能的趨勢。

影響**EMG**－肌力關係的眾多因素是該領域**研究**的主要挑戰。肌肉疲勞、收縮類型和個體差異等生理因素，以及電極放置和訊號處理等技術細節，都可能顯著改變**EMG**訊號與實際肌力輸出之間的映射。因此，在應用**EMG**進行肌力評估時，必須嚴格控制實驗條件，採用標準化流程，並充分考慮這些影響因素。**Carson**等人 (2024) 發起的 **CEDE (Consensus for Experimental Design in Electromyography)** 項目，旨在為**EMG**實驗設計提供共識性指導，這對於提高**研究**的可重複性和結果的可靠性至關重要。

未來的**研究**方向可能包括：

- (1) 開發更可靠和個體化的**EMG**－肌力模型，能夠適應不同個體、任務和生理狀態的變化；
- (2) 結合高密度**EMG (HD-EMG)** 技術，以獲取更豐富的肌肉活動空間資訊，從而更精細地解析肌內力學；
- (3) 融合多模態傳感資訊（如超聲、近紅外光譜、慣性測量單元），以彌補單一**EMG**訊號的不足；
- (4) 進一步探索肌肉疲勞對**EMG**－肌力關係的動態影響，並開發能夠在線監測和補償疲勞效應的模型。

結論

EMG訊號幅度，特別是其均方根值，與肌力之間存在顯著的正相關性，使其成為評估肌肉功能的重要工具。量化這種關係的模型從簡單的線性回歸發展到複雜的機器學習算法，不斷提升著預測的準確性。然而，研究者和實踐者必須認識到，這種關係受到眾多生理、生物力學和技術因素的深刻影響。為了準確地從**EMG**推斷肌力，必須仔細選擇模型、嚴格控制實驗條件、採用標準化流程，並結合對影響因素的深入理解。通過持續的方法學創新和對基礎生理機制的探索，**EMG**技術在肌力評估領域的應用潛力將得到進一步的釋放。

參考文獻

- Burden, A. (2010). How should we normalize electromyograms obtained from healthy participants? What we have learned from voluntary submaximal activations. *Journal of Electromyography and Kinesiology*, 20(6), 1023–1035. <https://doi.org/10.1016/j.jelekin.2010.05.008>
- Carson, R. G., Besomi, M., Søgaard, K., Holobar, A., Enoka, R. M., Wrigley, T. V., Disselhorst-Klug, C., Hug, F., Merletti, R., Farina, D., Falla, D., Perreault, E. J., Besier, T. F., Dick, T. J. M., Kiernan, M. C., Clancy, E. A., Tucker, K. J., Rothwell, J. C., Gandevia, S. C., Lowery, M. M., Van Dieën, J. H., Hodges, P. W., & McGill, K. C. (2024). Consensus for experimental design in electromyography (CEDE) project: Application of EMG to estimate muscle force. *Journal of Electromyography and Kinesiology*, 77, 102910. <https://doi.org/10.1016/j.jelekin.2024.102910>
- Chaffin, D. B., Freivalds, A., & Lee, M. W. (1980). Muscle strength assessment from EMG analysis. *Medicine and Science in Sports and Exercise*, 12(3), 205–211. <https://doi.org/10.1249/00005768-198023000-00014>
- Cifrek, M., Medved, V., Tonković, S., & Ostojić, S. (2009). Surface EMG based muscle fatigue evaluation in biomechanics. *Clinical Biomechanics*, 24(4), 327–340. <https://doi.org/10.1016/j.clinbiomech.2009.01.010>
- De Luca, C. J. (1997). The use of surface electromyography in biomechanics. *Journal of Applied Biomechanics*, 13(2), 135–163. <https://doi.org/10.1123/jab.13.2.135>
- Ding, Y., Wang, X., Zheng, Z., Luo, B., Sun, X., Yu, S., Wang, D., & Wang, Z. (2024). A Pilot Study on Quantitative Muscle Strength Assessment Using EMG and Motion Data. 2024 17th International Convention on Rehabilitation Engineering and

Assistive Technology (i-CREATe), 1–5.

<https://doi.org/10.1109/i-CREATe62067.2024.10776455>

- Duchateau, J., & Enoka, R. M. (2016). Neural control of lengthening contractions. *Journal of Experimental Biology*, 219(2), 197-204.
- Enoka, R. M., & Duchateau, J. (2008). Muscle fatigue: what, why and how it influences muscle function. *The Journal of Physiology*, 586(1), 11–23.
<https://doi.org/10.1113/jphysiol.2007.139477>
- Farina, D., Merletti, R., & Enoka, R. M. (2004). The extraction of neural strategies from the surface EMG. *Journal of Applied Physiology*, 96(4), 1486–1495.
<https://doi.org/10.1152/japplphysiol.01070.2003>
- Gao, X., Zhang, X., Zhu, X., Tang, X., & Chen, X. (2017). Re-Evaluating Electromyogram-Force Relation in Healthy Biceps Brachii Muscles Using Complexity Measures. *Entropy*, 19(11), 624. <https://doi.org/10.3390/e19110624>
- Hof, A. L. (1984). EMG and muscle force: An introduction. *Human Movement Science*, 3(1-2), 119–153. [https://doi.org/10.1016/0167-9457\(84\)90008-3](https://doi.org/10.1016/0167-9457(84)90008-3)
- Karunakaran, S., Saranya, S., & Poonguzhali, S. (2020). Gaussian mixture model based clustering of Manual muscle testing grades using surface Electromyogram signals. *Physical and Engineering Sciences in Medicine*, 43(3), 837–847.
<https://doi.org/10.1007/s13246-020-00880-5>
- Liu, Q., Zheng, N., Tan, J., Lin, X., Zhan, M., & Li, Y. (2025). Natural Control of Muscle Strength Training Instrument Based on EMG-Driven Multistep Ahead Models. *IEEE Transactions on Instrumentation and Measurement*, 74, 1–13.
<https://doi.org/10.1109/TIM.2025.3546405>
- Merletti, R., Rainoldi, A., & Farina, D. (2001). Myoelectric manifestations of muscle fatigue. *European Journal of Applied Physiology*, 84(3), 234–240.
<https://doi.org/10.1007/s004210000361>
- Qijun, L., & Fangteng, Z. (2021). Research on Improved SVR Strength Smart Prediction Using Support Vector Machine Regression Algorithm and sEMG. 2021 IEEE International Conference on Data Science and Computer Application (ICDSCA), 142–143. <https://doi.org/10.1109/ICDSCA53499.2021.9650190>
- Saranya, S., & Poonguzhali, S. (2023). A resistive force correlated electromyogram feature selection method for muscle strength prediction. *Biomedical Signal Processing and Control*, 79, 104174. <https://doi.org/10.1016/j.bspc.2022.104174>
- Staudenmann, D., Roeleveld, K., Stegeman, D. F., & van Dieën, J. H. (2010). Methodological aspects of SEMG amplitude and spectral analyses. *Journal of*

Electromyography and Kinesiology, 20(3), 375–387.

<https://doi.org/10.1016/j.jelekin.2009.08.005>

- Watanabe, K., Kouzaki, M., Akima, H., Moritani, T., & Ogawa, M. (2018). Relationships between muscle strength and multi-channel surface EMG parameters in eighty-eight elderly. *European Review of Aging and Physical Activity*, 15, 4.
<https://doi.org/10.1186/s11556-018-0192-z>
- Xiahou, S., Shan, X., Luo, X., & Ma, L. (2024). A Laguerre-Volterra network model based on ant colony optimization applied to evaluate EMG-force relationship in the muscle fatigue state. *The Review of Scientific Instruments*, 95(6), 064101.
<https://doi.org/10.1063/5.0180054>

演算法演進的三階段

針對演算法演進的三階段

- **Step 1: 相對比較**

個人做為個人的演算法基礎值(baseline), 並從未來的量測主題上, 定義使用者想要看的有意義資訊, 可能包括但不限於 A. 當前的肌力數值、 B. 與過去相比的成長/退步、 C. 長期累積的趨勢觀察、 D. 與其他同數據基礎樣態相近者的比較。

- **Step 2: 絕對數據** - 長期取得大量用戶數據後, 如何建立分群的 baseline 以及可能的偵測及預警系統。

- **Step 3: 長期累積的個人數據後, 如何建立超個個人模型, 供 AI 智能教練提供主動的回饋及訓練的引導。**

互動規劃: 個人AI健身教練

我們的目標: 將您的手機和EMG感測器, 變成一位真正懂你的、24小時待命的頂尖私人健身教練。

核心理念: 從「盲目訓練」到「精準溝通」

傳統健身, 我們只能感覺「累不累」、「酸不酸」。而我們的演算法 就像一個翻譯官, 能即時「讀懂」你肌肉的真實語言, 並將其翻譯成你能理解的建議, 讓你和你的身體之間, 第一次實現精準溝通。

演算法四大階段

第一階段: 建立您的「個人專屬檔案」

目標: 在您第一次使用APP時, 花3分鐘做一個簡單的「體能檢測」, 讓APP認識您獨一無二的身體。

運作邏輯:

1. 引導式測試：APP會像教練一樣，用清晰的語音和動畫，引導您針對一塊核心肌肉（例如大腿）做幾個簡單的動作。
 - 「全力測試」：首先，APP會請您用盡全力收縮一次肌肉。
 - 目的：讓APP知道您「100%的力量」是什麼水平，這就像是設定了您力量的「最高分」。
 - 「多力道測試」：接著，APP會請您分別用「輕、中、重」三種不同的力道，再各收縮一次。
 - 目的：讓APP學習並建立一個專屬於您的「力量-肌肉訊號」換算模型。從此以後，APP就能非常準確地知道，您出的每一分力，對應的是多大的肌肉訊號。

完成後，您的個人專屬檔案就建立好了。這個檔案校正了所有因為您的體型、肌肉量、甚至皮膚出汗等個人因素造成的差異，確保後續分析的絕對個人化。

第二階段：訓練中，您的「即時語音教練」

目標：在您訓練的過程中，即時提供語音和視覺回饋，就像教練在旁邊喊話一樣，確保您的每一次動作都有效、安全。

運作邏輯：

1. 即時「力量儀表板」：
 - APP會顯示：一個動態的儀表盤，即時顯示您每一次發力的強度。
 - 它會告訴你：「剛剛這一下，您用了最大力量的75%！」這讓你對自己的用力程度有非常直觀的了解。
2. 即時「疲勞監測儀」：
 - APP會顯示：一個從綠色（體力充沛）到紅色（體力耗盡）的「體力條」。
 - 它如何知道你累了？演算法會分析您的肌肉訊號品質。當您開始疲勞時，肌肉訊號會變得「混亂」，即便您還在用力，APP也能偵測到這種細微變化。
 - 它會提醒你：當體力條進入紅色區域時，APP會發出語音提醒：「偵測到肌肉疲勞，注意安全，或考慮結束這一組！」

第三階段：訓練後，您的「個人進步報告」

目標：將您辛苦的汗水，轉化為看得見的、令人鼓舞的進步報告，讓您充滿成就感。

運作邏輯：

1. 自動生成圖表：訓練一結束，APP就會自動生成幾張簡單易懂的圖表。
2. 清晰的進步解讀：

- 「力量趨勢」圖：
 - 它會顯示：您最近一個月的力量成長曲線。
 - 它會總結：「恭喜！和上週比，您今天的平均力量輸出提升了5%，您的肌肉真的變強了！」
 - 「耐力趨勢」圖：
 - 它會顯示：您抵抗疲勞的能力變化。
 - 它會總結：「您的肌耐力進步明顯！上個月您做8下就會累，現在可以輕鬆完成12下了！」
3. AI智慧洞察 (報告的亮點)：
- 演算法會提供比數字更深度的分析。
 - 它可能會告訴你：「AI發現一個好消息：您現在舉起同樣的重量，比上個月更省力了（肌肉激活度降低）。這代表您的身體學會了更聰明的發力技巧，這是最高級的進步！」

第四階段：展望未來，您的「動態訓練計畫」

目標：讓您的訓練計畫不再一成不變。APP會像一位經驗豐富的教練，根據您的進步，自動優化未來的訓練內容。

運作邏輯：

1. 持續學習您的數據：APP後台的AI模型會持續分析您的所有訓練數據，學習您對不同訓練方式的反應。
2. 智慧調整計畫：
 - 它會發現：您的身體最近對「大重量、低次數」的訓練反應特別好。
 - 它會建議：「根據您的數據，下週的訓練計畫已為您自動增加了大重量訓練的比例，預計能帶來最大程度的肌力增長。是否採納？」
 - 它也會發現：您最近的疲勞累積得比較快。
 - 它會建議：「為了讓身體充分恢復，下週的計畫已為您自動安排了一個額外的休息日。」

EMG 個人化模型的可能性：

EMG 能做為”個人”身份識別的技術。因此以”獨立使用者”的 **EMG** 做為數據建模之應用，已有先例。

1. Personalized and Adaptive EMG-Based Motor Decoding Framework

- 這項**2025**年的**研究**提出一個個人化且自適應的手部運動解碼框架，針對不同個體、不同時段及同一時段內**EMG**信號的變異性進行調整，提升義肢控制的準確度。該框架結合多種分類器與特徵擷取方法，並透過無監督學習進行模型調整，顯著改善分類準確率^{[1][2]}。

1. <https://pubmed.ncbi.nlm.nih.gov/40073448/>

2. Electromyography-Driven Musculoskeletal Models with Time-Varying Parameters

- 這篇**研究**建立了針對個人及特定肌肉的模型，用以追蹤功能性任務中的肌肉疲勞，強調模型的個人化特性以提升預測準確度^[3]。

<https://www.sciencedirect.com/science/article/pii/S0021929024000642>

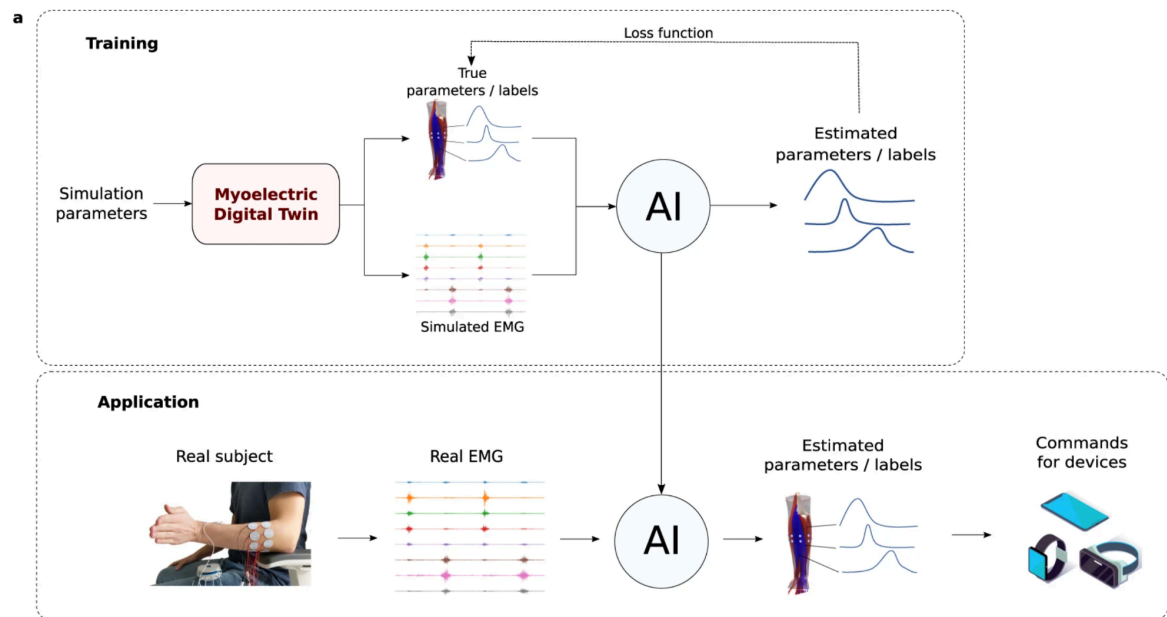
3. Myoelectric Digital Twin for EMG Simulation and Deep Learning

- **2023**年發表的**研究**介紹「肌電數位雙胞胎」 (**Myoelectric Digital Twin**) 概念，利用高效且逼真的電腦模擬生成大量個人化**EMG**數據，供深度學習模型訓練使用。此方法解決了實際收集大量高品質標註**EMG**數據的困難，並能在無需校正的情況下，將訓練好的模型直接應用於真實個體的肌電信號解碼，實現精準的肌肉力量重建與動作控制^[4]。

<https://www.nature.com/articles/s41467-023-37238-w>

Fig. 1: Simulation pipeline.

From: [A myoelectric digital twin for fast and realistic modelling in deep learning](#)




4. Wearable EMG for Personalized Musculoskeletal Trunk Models

- 這項研究探討穿戴式**EMG**系統結合逆向協同作用方法，建立個人化的軀幹肌肉骨骼模型，提升對肌肉活動的估計與分析能力^[5]。

https://research.utwente.nl/files/481830277/Towards_Wearable_Electromyography_for_Personalized_Musculoskeletal_Trunk_Models_Using_an_Inverse_Synergy-Based_Approach.pdf

EMG 的振幅與肌力正相關



Watanabe, K., Kouzaki, M., Ogawa, M., Akima, H., & Moritani, T. (2018). Relationships between muscle strength and multi-channel surface EMG parameters in eighty-eight elderly. *European Review of Aging and Physical Activity*, 15, 1-10.

<https://eurapa.biomedcentral.com/articles/10.1186/s11556-018-0192-z>